

Ajuste de Curvas: Mínimos Cuadrados

Guía Teórica y Práctica

5 de junio de 2026

1. Introducción

En el análisis de datos y métodos numéricos, frecuentemente nos encontramos con un conjunto de puntos experimentales $(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)$ que no se comportan de manera perfectamente analítica debido a errores de medición o a la naturaleza misma del fenómeno. El objetivo del ajuste de curvas no es encontrar una función que pase exactamente por todos los puntos (como en la interpolación), sino hallar una función $y = f(x)$ que represente la **tendencia general** de los datos.

El método más utilizado para este fin es el de los **Mínimos Cuadrados**, el cual busca minimizar la suma de los cuadrados de las diferencias (residuos) entre los valores observados y los valores calculados por el modelo matemático elegido.

2. Fundamentos Teóricos

El principio de mínimos cuadrados se basa en la optimización de funciones de varias variables. Dado un modelo lineal $f(x) = a_0 + a_1x$, definimos el residuo o error en el i -ésimo punto como $e_i = y_i - f(x_i)$.

2.1. Función de Error

Queremos encontrar los parámetros a_0 y a_1 que hagan mínima la suma de los errores al cuadrado. Definimos la función de coste $g(a_0, a_1)$:

$$g(a_0, a_1) = \sum_{i=1}^m (y_i - f(x_i))^2 = \sum_{i=1}^m (y_i - a_0 - a_1x_i)^2$$

2.2. Optimización por Derivadas Parciales

Según el cálculo diferencial multivariable, para hallar el mínimo de la función g , debemos calcular sus derivadas parciales respecto a a_0 y a_1 , e igualarlas a cero. Esto garantiza que encontramos el punto crítico de la superficie de error.

3. Demostración de las Ecuaciones Normales

A partir de la función $g(a_0, a_1)$, calculamos las derivadas parciales:

1. Derivada parcial respecto a a_0 :

$$\frac{\partial g}{\partial a_0} = \sum_{i=1}^m 2(y_i - a_0 - a_1 x_i)(-1) = 0$$

Dividiendo por -2 y distribuyendo la sumatoria:

$$\sum_{i=1}^m y_i - \sum_{i=1}^m a_0 - \sum_{i=1}^m a_1 x_i = 0$$

Sabiendo que sumar a_0 un número m de veces es $m \cdot a_0$, reorganizamos para obtener la **primera ecuación normal**:

$$ma_0 + a_1 \sum_{i=1}^m x_i = \sum_{i=1}^m y_i$$

2. Derivada parcial respecto a a_1 :

$$\frac{\partial g}{\partial a_1} = \sum_{i=1}^m 2(y_i - a_0 - a_1 x_i)(-x_i) = 0$$

Dividiendo por -2 , multiplicando x_i y distribuyendo la sumatoria:

$$\sum_{i=1}^m x_i y_i - a_0 \sum_{i=1}^m x_i - a_1 \sum_{i=1}^m x_i^2 = 0$$

Reorganizando los términos, obtenemos la **segunda ecuación normal**:

$$a_0 \sum_{i=1}^m x_i + a_1 \sum_{i=1}^m x_i^2 = \sum_{i=1}^m x_i y_i$$

En forma matricial, el sistema ($A\mathbf{x} = \mathbf{b}$) se expresa como:

$$\begin{pmatrix} m & \sum x_i \\ \sum x_i & \sum x_i^2 \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} \sum y_i \\ \sum x_i y_i \end{pmatrix}$$

4. Transformación de Modelos No Lineales

En muchas aplicaciones, los datos no siguen un patrón lineal. Sin embargo, podemos usar transformaciones logarítmicas para llevar estos modelos a una forma lineal $Y = A_0 + A_1 X$, resolver el sistema, y luego regresar a los parámetros originales.

4.1. Modelo Exponencial: $y = ae^{bx}$ (o $y = ab^x$)

Aplicamos logaritmo natural ($\ln$) a ambos lados:

$$\ln(y) = \ln(a) + bx$$

Haciendo los cambios de variable: $Y = \ln(y)$, $X = x$, $A_0 = \ln(a)$, $A_1 = b$. Al resolver, se recupera $a = e^{A_0}$ y $b = A_1$.

4.2. Modelo Potencial: $y = ax^b$

Aplicamos logaritmo natural ($\ln$) a ambos lados:

$$\ln(y) = \ln(a) + b \ln(x)$$

Haciendo los cambios de variable: $Y = \ln(y)$, $X = \ln(x)$, $A_0 = \ln(a)$, $A_1 = b$. Al resolver, se recupera $a = e^{A_0}$ y $b = A_1$.

5. Ejemplo de Aplicación Práctica: Modelo Potencial

Enunciado: Encuentre el modelo de mejor ajuste de la forma $y = ax^b$ para el siguiente subconjunto de datos experimentales.

x_i	1	1.3	2	2.5
y_i	5.3	8.279	17.219	25.163

Solución: Como es un modelo potencial, definimos $X = \ln(x)$ y $Y = \ln(y)$. Construimos la tabla extendida para hallar las sumatorias de nuestro sistema lineal equivalente ($Y = a_0 + a_1X$).

x_i	y_i	$X_i = \ln(x_i)$	$Y_i = \ln(y_i)$	X_i^2	X_iY_i
1	5.3	0	1.6677	0	0
1.3	8.279	0.2623	2.1137	0.0688	0.5545
2	17.219	0.6931	2.8460	0.4804	1.9727
2.5	25.163	0.9162	3.2254	0.8395	2.9554
Σ	-	1.8716	9.8528	1.3887	5.4826

Para $m = 4$ datos, planteamos el sistema de ecuaciones normales:

$$\begin{cases} 4a_0 + 1,8716a_1 = 9,8528 \\ 1,8716a_0 + 1,3887a_1 = 5,4826 \end{cases}$$

Al resolver este sistema lineal de 2×2 , obtenemos:

$$a_0 = 1,6677 \quad \text{y} \quad a_1 = 1,7000$$

Finalmente, recuperamos los parámetros originales del modelo potencial:

$$b = a_1 = 1,7$$

$$a = e^{a_0} = e^{1,6677} \approx 5,3$$

El modelo de mejor ajuste es: $y = 5,3x^{1,7}$.




Figura 1: Representación visual del modelo potencial analítico frente a la dispersión de los puntos experimentales estudiados. Se aprecia geoméricamente el comportamiento asintótico de la función minimizando el cuadrado global de los residuos verticales.